

Lineamientos del Trabajo Final

Aprendizaje Automático aplicado a Problemas Reales

Maestría en Ciencia de Datos - Universidad Católica del Uruguay (UCU)

2026-07-06

Tabla de contenidos

1	Introducción y Objetivo del Trabajo	1
2	Ámbito de Aplicación y Valor Agregado	2
3	Estructura y Requisitos Metodológicos del Proyecto	2
3.1	Formulación del Problema e Impacto (10 %)	2
3.2	Adquisición y Análisis Exploratorio de Datos (EDA) (20 %)	2
3.3	Feature Engineering y Preprocesamiento (20 %)	2
3.4	Modelado e Hiperparámetros (20 %)	3
3.5	Evaluación Orientada al Negocio e Interpretabilidad (15 %)	3
4	Entregables del Proyecto	3

1. Introducción y Objetivo del Trabajo

El objetivo del Trabajo Final es aplicar de manera práctica y reproducible los conceptos teóricos y prácticos de Machine Learning desarrollados a lo largo del curso. Los estudiantes deberán abordar un problema del mundo real utilizando datos reales (propios o fuentes disponibles en internet), justificar el valor operativo y de negocio de su solución, y seguir las mejores prácticas metodológicas del ciclo de vida de un modelo.

El trabajo se puede realizar de forma individual o en grupos de hasta tres personas.

2. **Ámbito de Aplicación y Valor Agregado**

Cualquier proyecto de Machine Learning debe nacer de una necesidad concreta. El trabajo final no debe limitarse a optimizar una métrica técnica abstracta (como la precisión o el AUC) sino que debe conectar esa métrica con un **ámbito de aplicación real** y mostrar dónde y cómo agrega valor.

3. **Estructura y Requisitos Metodológicos del Proyecto**

El desarrollo del proyecto debe seguir las siguientes etapas, las cuales deberán quedar documentadas en el informe final:

3.1. **Formulación del Problema e Impacto (10 %)**

- Definición clara del problema y tipo de aprendizaje (clasificación tabular, regresión, series temporales, visión por computadora, etc.).
- Justificación del ámbito de aplicación y la propuesta de valor.
- Definición de las métricas clave de éxito técnico y de negocio.

3.2. **Adquisición y Análisis Exploratorio de Datos (EDA) (20 %)**

- Identificación de la fuente de datos reales y descripción de sus variables.
- Análisis de la calidad de los datos (datos faltantes, tipos de datos, anomalías).
- Estudio de distribuciones, correlaciones y relaciones con la variable objetivo.
- En problemas de clasificación, analizar el desbalance de clases y proponer cómo mitigarlo si es necesario.

3.3. **Feature Engineering y Preprocesamiento (20 %)**

- En caso de ser necesario realizar imputación de valores faltantes, escalado de variables o feature engineering.
- **Crítico:** Implementar pipelines de datos para evitar la contaminación de los datos de entrenamiento (data leakage).

3.4. Modelado e Hiperparámetros (20 %)

- Establecer un **baseline simple** (un modelo ingenuo o un modelo lineal básico como Regresión Logística o Regresión Lineal) para contrastar el valor de las soluciones complejas.
- Implementar y comparar al menos **dos familias de algoritmos** estudiadas en el curso (p. ej., modelos basados en árboles, KNN, Redes Neuronales).
- Ajustar hiperparámetros.

3.5. Evaluación Orientada al Negocio e Interpretabilidad (15 %)

- Evaluar modelos utilizando métricas correctas.
- Implementar un **análisis de costos y toma de decisiones** (Threshold Moving) en caso de ser necesario.

4. Entregables del Proyecto

Los estudiantes deberán entregar los siguientes componentes al finalizar el curso:

1. Repositorio de GitHub:

- Estructura organizada.
- Archivo `README.md` que explique claramente cómo reproducir el entorno y cómo ejecutar el pipeline de entrenamiento.

2. Informe Técnico (en formato PDF):

- Un reporte detallando la formulación, el análisis exploratorio, el diseño del pipeline, los resultados comparativos de modelos (tablas con métricas y gráficas de curvas de rendimiento) y el análisis de costos del negocio.