

Obligatorio 2026 — Machine Learning

Ángel Mamberto

10/08/2026

Índice

1. Introducción	3
1.1. Contexto y motivación	3
1.2. Formulación del problema	3
1.3. Propuesta de valor	3
1.4. Objetivos	3
1.5. Alcance	4
2. Datos	4
2.1. Fuente y unidad de análisis	4
2.2. Calidad de los datos	4
2.3. Diferencias entre hoteles y comportamiento temporal	5
2.4. Reservas repetidas	5
2.5. Disponibilidad temporal y fugas de información	6
3. Metodología	7
3.1. Momento de predicción y disponibilidad de la información	7
3.2. Análisis de variables	7
3.3. Identificadores de agencia y empresa	7
3.4. Variables candidatas e hipótesis de transformación	7
3.5. Validación y selección de variables	8
3.6. Baseline y preprocesamiento	8
3.7. Evaluación operativa y valor estimado	8
3.8. Política preventiva propuesta	9
3.9. Primer lote de ingeniería de variables	9
3.10. Segundo lote de ingeniería de variables	10
3.11. Regresión logística mejorada	10
3.12. Árbol de decisión e importancia de variables	10
3.13. Random Forest	11
3.14. XGBoost	11
3.15. KNN	11
3.16. Red neuronal MLP	11
3.17. Modelos y criterio de evaluación	12
4. Resultados	12
4.1. Baseline técnico	12
4.2. Primer lote de ingeniería de variables	12
4.3. Segundo lote de ingeniería de variables	13
4.4. Regresión logística mejorada	13
4.5. Árbol de decisión	14
4.6. Random Forest	14

4.7. XGBoost	15
4.8. KNN	15
4.9. Red neuronal MLP	15
4.10. Comparación operativa a igual capacidad	16
4.11. Diagnóstico del desalineamiento del objetivo	17
4.12. Del baseline al modelo económico final	18
4.13. Evaluación económica por escenarios	18
5. Conclusiones	19
5.1. Limitaciones	19
5.2. Trabajo futuro	20

1. Introducción

1.1. Contexto y motivación

Las cancelaciones representan una fuente de incertidumbre para la gestión hotelera. Una habitación reservada que finalmente no se ocupa puede ocasionar una pérdida de ingresos cuando el hotel no dispone de tiempo o demanda suficiente para volver a comercializarla. Al mismo tiempo, aplicar medidas preventivas sobre todas las reservas puede incrementar los costos operativos, reducir el margen o generar fricción con clientes que no tenían intención de cancelar.

Disponer anticipadamente de una estimación del riesgo de cancelación puede ayudar al hotel a administrar esa incertidumbre. En lugar de intervenir de manera indiscriminada, las probabilidades estimadas podrían utilizarse para priorizar una capacidad limitada de acciones, como solicitar confirmación, ofrecer una alternativa de reprogramación o requerir determinadas garantías.

1.2. Formulación del problema

El trabajo plantea un problema de clasificación binaria cuyo objetivo es estimar la probabilidad de que una reserva hotelera sea cancelada. Cada observación representa una reserva y la variable objetivo distingue entre reservas canceladas y no canceladas.

Se definió como momento de predicción el instante posterior a la confirmación y registro de la reserva. Este momento permite iniciar acciones preventivas con anticipación y utilizar solamente información ya disponible, evitando contaminación con datos generados durante la evolución o el desenlace de la reserva («data leakage»).

1.3. Propuesta de valor

La propuesta consiste en utilizar el riesgo estimado para priorizar reservas sobre las cuales aplicar una acción preventiva. El modelo no determina por sí mismo que una reserva deba ser modificada o rechazada, sino que aporta información para apoyar una decisión operativa.

El valor potencial del sistema depende tanto de su capacidad predictiva como de la efectividad y el costo de la acción elegida. Un falso negativo representa una oportunidad perdida de intervenir sobre una reserva que finalmente se cancela. Un falso positivo implica actuar innecesariamente sobre una reserva que se habría concretado. Por este motivo, la evaluación no se limitó a una métrica técnica, sino que incorporó distintos escenarios de capacidad, costos y efectividad.

1.4. Objetivos

El objetivo general es desarrollar y evaluar un sistema de clasificación que permita identificar reservas con riesgo de cancelación y analizar si su uso puede mejorar el resultado esperado frente a políticas sin priorización o basadas en reglas simples.

Los objetivos específicos son:

- evaluar la calidad, estructura y distribución de los datos;
- identificar y excluir variables que produzcan contaminación con información futura;
- analizar la relación entre las variables disponibles y la cancelación de las reservas;
- diseñar un preprocesamiento reproducible mediante pipelines;
- formular y evaluar nuevas variables sustentadas en hipótesis sobre el problema;
- establecer baselines y comparar diferentes familias de modelos;
- ajustar los hiperparámetros de los modelos más prometedores;

- analizar la importancia y el efecto de las variables sobre las predicciones;
- comparar políticas de decisión a igual capacidad, conservando el umbral 0,5 como referencia técnica; y
- comparar el valor esperado del modelo con estrategias alternativas de intervención.

1.5. Alcance

El estudio se desarrolló sobre datos históricos de reservas de dos hoteles reales. Se compararon modelos lineales, modelos basados en árboles, métodos basados en distancia y una red neuronal, utilizando una estrategia común de validación.

El análisis económico se presentó mediante escenarios, dado que el conjunto de datos no registra el costo real de una intervención ni su efecto causal sobre la cancelación. En consecuencia, los resultados permiten evaluar el potencial de una política de priorización, pero no demostrar que una acción específica evita cancelaciones en un entorno productivo.

2. Datos

2.1. Fuente y unidad de análisis

Se utilizaron los conjuntos H1 y H2 publicados por António, de Almeida y Nunes en *Hotel booking demand datasets*. Los datos corresponden a reservas reales de dos establecimientos portugueses: un resort hotel y un city hotel. La documentación y los datos originales se encuentran disponibles junto con la publicación¹.

Cada observación representa una reserva. Los archivos fueron integrados y se agregó la variable **HotelType** para conservar su procedencia. El dataset resultante contiene 119.390 reservas y 32 columnas: 31 variables originales y el identificador del hotel. El City Hotel aporta 79.330 registros (66,45 %) y el Resort Hotel 40.060 (33,55 %). El período observado se extiende desde julio de 2015 hasta agosto de 2017; solamente 2016 contiene los doce meses.

La variable objetivo es **IsCanceled**, que vale uno cuando la reserva fue cancelada y cero en caso contrario. Se registran 44.224 cancelaciones (37,04 %) y 75.166 reservas no canceladas (62,96 %). Existe cierto desbalance entre las clases, aunque no es extremo.

2.2. Calidad de los datos

La limpieza inicial eliminó espacios exteriores en variables de texto y convirtió la etiqueta NULL en un valor ausente real. Los nulos se concentran en **Company** (112.593), **Agent** (16.340), **Country** (488) y **Children** (4). En **Agent** y **Company** la ausencia parece ser principalmente estructural: una agencia o una empresa no intervienen en todas las operaciones. Por este motivo no se asumió que correspondiera imputarlas mediante la categoría más frecuente.

Se encontraron 180 reservas sin huéspedes registrados, 715 con cero noches y 70 que cumplen ambas condiciones. La mayoría presenta estado final **Check-Out**. Debido a su baja frecuencia y a que podían representar registros operativos válidos, se conservaron en el análisis. También se detectaron dos registros con 9 y 10 bebés.

La variable **ADR** presenta un valor negativo de $-6,38$ y un máximo de 5400, ampliamente separado del segundo mayor valor, 510. Además, fue calculada a partir de transacciones de alojamiento sin un corte temporal que garantice que represente el precio disponible al confirmar la reserva. Como su asociación marginal con el target resultó pequeña, se optó por excluirla: el beneficio potencial no compensa el riesgo de contaminación temporal ni la complejidad introducida por sus extremos.

¹<https://pmc.ncbi.nlm.nih.gov/articles/PMC6297060/>




Figura 1: Distribución de la variable objetivo.

2.3. Diferencias entre hoteles y comportamiento temporal

La tasa de cancelación del City Hotel es 41,73 %, frente a 27,76 % en el Resort Hotel. Esta comparación se limita a dos establecimientos concretos: **HotelType** puede resumir diferencias operativas, comerciales y geográficas que no fueron registradas directamente.




Figura 2: Volumen de reservas y tasa de cancelación por hotel.

El análisis mensual muestra indicios de estacionalidad, especialmente en el Resort Hotel, cuya tasa varía aproximadamente entre 15 % y 33 %. En el City Hotel se mantiene aproximadamente entre 37 % y 46 %. Sin embargo, el período contiene un solo año completo; estos resultados se consideran patrones descriptivos y no evidencia de un ciclo estable para años futuros.

2.4. Reservas repetidas

El 33,64 % de las filas pertenece a combinaciones exactamente repetidas y estos registros concentran el 53,03 % de todas las cancelaciones. Su tasa de cancelación es 58,39 %, frente a 26,22 % en las combinaciones únicas. La tasa también aumenta con el tamaño del bloque y alcanza 95,58 % cuando una combinación aparece más de 50 veces.

No se eliminaron estas observaciones: pueden representar reservas diferentes pertenecientes a




Figura 3: Volumen medio y tasa de cancelación por mes calendario.

contingentes o bloques gestionados conjuntamente y su peso económico es real. Una deduplicación hipotética reduciría la tasa global de cancelación de 37,04 % a 27,49 %, alterando sustancialmente el problema. En cambio, la estrategia de validación se diseñó para impedir que combinaciones idénticas aparecieran simultáneamente en entrenamiento y validación.

2.5. Disponibilidad temporal y fugas de información

El riesgo se estimó una vez que la reserva había sido confirmada y registrada. En ese momento `DaysInWaitingList` es admisible: se define como la cantidad de días transcurridos en lista de espera antes de la confirmación al cliente.

`ReservationStatus` revela directamente la variable objetivo: todos los registros `Canceled` y `No-Show` tienen `IsCanceled`=1, mientras que todos los `Check-Out` tienen valor cero. `ReservationStatusDate` registra la fecha en la que se produjo ese desenlace. Ambas variables se excluyeron de todos los modelos.

`DepositType` también se excluye. Aunque su nombre puede interpretarse como una política contractual, en este dataset fue construida a partir de los pagos acumulados antes de la llegada o cancelación. Su valor no está disponible de forma consistente inmediatamente después de confirmar la reserva.

`AssignedRoomType` y `BookingChanges` también se excluyen del escenario principal porque su valor puede generarse o cambiar después de la confirmación. Podrían considerarse en un modelo operativo posterior si se definiera un horizonte fijo y pudiera reconstruirse el valor disponible en ese momento.

Las decisiones de imputación, tratamiento de extremos, codificación y selección de variables no se fijaron durante el análisis exploratorio. Se evaluaron posteriormente de manera reproducible en las etapas de análisis e ingeniería de variables.

3. Metodología

3.1. Momento de predicción y disponibilidad de la información

El sistema estima el riesgo inmediatamente después de que la reserva haya sido confirmada y registrada. Esta definición determina qué variables pueden utilizarse: cada predictor debe estar disponible en ese instante y no puede incorporar información generada durante la evolución o el desenlace de la reserva.

Como consecuencia, se excluyeron `ReservationStatus` y `ReservationStatusDate`, que revelan directamente el resultado. También se descartaron `AssignedRoomType` y `BookingChanges`, cuyos valores pueden definirse o modificarse después de la confirmación. Aunque `DepositType` parece describir una condición inicial, en este dataset fue construido a partir de pagos acumulados antes de la llegada o cancelación, por lo que no garantiza disponibilidad en el momento elegido. Finalmente, `ADR` fue excluida debido a la ambigüedad temporal de su cálculo, la presencia de valores extremos y su asociación marginal débil con el objetivo.

3.2. Análisis de variables

Las variables se clasificaron según su naturaleza semántica antes de decidir su codificación. Para las categóricas se aplicó una prueba de independencia chi-cuadrado y se utilizó la V de Cramér corregida como medida de magnitud de la asociación. El valor p no se interpretó como medida de importancia: con 119.390 observaciones, diferencias pequeñas pueden resultar estadísticamente significativas. Los resultados se complementaron con tasas de cancelación por categoría y análisis condicionados por hotel, período y repetición de combinaciones.

Para las variables numéricas se estudiaron sus distribuciones, valores extremos, correlación de Spearman con el objetivo y ROC AUC univariado. Estas métricas se emplearon con fines descriptivos y no como un mecanismo automático de selección, dado que una variable con señal marginal pequeña puede resultar útil mediante relaciones no lineales o interacciones dentro de un modelo.

3.3. Identificadores de agencia y empresa

Los identificadores `Agent` y `Company` presentan alta cardinalidad y aparecen nuevas entidades entre períodos. Utilizarlos de forma directa podría inducir al modelo a memorizar actores particulares y dificultar su generalización. Además, la ausencia de estos valores es principalmente estructural y no equivale a un dato desconocido.

Por este motivo se decidió sustituir ambos identificadores por los indicadores binarios `HasAgent` y `HasCompany`. De esta manera se conserva la distinción operativa entre reservas con y sin intermediación, sin depender de la identidad concreta de cada agencia o empresa.

3.4. Variables candidatas e hipótesis de transformación

`Country` se conserva como variable nominal: mostró una asociación relevante con la cancelación, aunque parte de ella está relacionada con el hotel y con combinaciones repetidas. Se evaluó además el indicador `IsDomestic`; las agrupaciones de categorías infrecuentes se utilizaron únicamente con fines descriptivos en el análisis de asociaciones. Las transformaciones candidatas se calcularon sin utilizar el objetivo y exclusivamente con la información disponible en cada partición para evitar contaminación.

Se propusieron `TotalGuests`, suma de adultos, niños y bebés, y `TotalNights`, suma de noches de semana y fin de semana. Estas variables son interpretables, pero su ROC AUC individual no superó al mejor de sus componentes. Por ello se trataron como candidatas y no reemplazaron inicialmente las columnas originales; su aporte se comprobó mediante ablación.

La relación de `DaysInWaitingList` con la cancelación cambia de dirección según el hotel, varía entre años y se debilita al reducir el peso de las combinaciones repetidas. El valor numérico se conservó para modelos basados en árboles. En modelos lineales se evaluó una versión binaria, `WasOnWaitingList`, junto con su interacción con `HotelType`, en lugar de asumir un efecto lineal común.

Las reservas sin huéspedes o con cero noches se conservaron. Representan una proporción pequeña y el análisis exploratorio mostró que pueden corresponder a registros operativos válidos. Los pocos valores extremos de cantidad de huéspedes y duración tampoco se eliminaron mediante reglas globales. Los nulos admisibles se imputaron dentro del pipeline y las transformaciones se validaron fuera de muestra.

El análisis de redundancia posterior al baseline no encontró multicolinealidad relevante entre las variables numéricas originales: el mayor VIF fue 1,52. La principal redundancia apareció entre `ArrivalDateMonth` y `ArrivalDateWeekNumber`, con razón de correlación $\eta = 0,9951$. Como mes, año y día permiten una representación temporal más interpretable, `ArrivalDateWeekNumber` se excluyó de los conjuntos mejorados. Se mantuvo en el baseline histórico para preservar la reproducibilidad de ese experimento.

3.5. Validación y selección de variables

La presencia de combinaciones repetidas y el alcance temporal del dataset impiden utilizar una división aleatoria ingenua como única evidencia de generalización. Se utilizaron las reservas de 2015 y 2016 como conjunto de desarrollo y se reservó el período enero–agosto de 2017 como holdout temporal. Este holdout aproxima el desempeño sobre observaciones posteriores, aunque no representa un año calendario completo.

La selección de hiperparámetros dentro del conjunto de desarrollo utilizó cinco particiones de `StratifiedGroupKFold`. Los grupos se construyeron a partir de combinaciones idénticas de predictores, de modo que las repeticiones exactas no aparecieran simultáneamente en entrenamiento y validación interna. El holdout temporal no participó en la selección.

Todas las imputaciones, codificaciones, escalados y transformaciones se ajustaron dentro de pipelines utilizando solamente los datos de entrenamiento. Las nuevas variables se compararon contra un conjunto base común. La selección final consideró ROC AUC fuera de muestra, estabilidad entre particiones e interpretabilidad, y se apoyó en experimentos de ablación en lugar de decidir únicamente a partir de asociaciones calculadas sobre el dataset completo.

3.6. Baseline y preprocesamiento

Se establecieron dos referencias iniciales. Un `DummyClassifier` con estrategia `prior` representa el desempeño sin aprendizaje predictivo. La segunda referencia es una regresión logística entrenada sobre el conjunto original depurado, antes de incorporar nuevas variables.

Las variables numéricas se imputaron por mediana y se estandarizaron. Las categóricas se imputaron por moda y se codificaron mediante One-Hot Encoding, ignorando categorías desconocidas en validación. Todas las operaciones se ajustaron dentro de un *pipeline*. La búsqueda ligera comparó $C \in \{0,1; 1; 10\}$ y `class_weight` con valores `None` y `balanced`, utilizando ROC AUC como criterio de selección.

3.7. Evaluación operativa y valor estimado

El modelo conserva como objetivo cualquier cancelación. Para aproximar su utilidad operativa se definió además un evento crítico: un `No-Show` o una cancelación registrada entre cero y siete días antes de la llegada. Esta clasificación utiliza `ReservationStatus` y `ReservationStatusDate` únicamente después de predecir; estas variables no ingresan al modelo.

El valor bruto de una reserva se aproximó como

$$\text{EstimatedBookingValue} = \text{ADR} \times \text{TotalNights}.$$

Esta cantidad no constituye una pérdida contable observada, porque el dataset no registra pagos, penalizaciones, reventa de habitaciones ni costos evitados. El registro con $\text{ADR}=5400$ y el único ADR negativo se excluyeron de la valoración. Para cada evento crítico i , la pérdida estimada se definió como

$$L_i = V_i \times m \times r_{t_i},$$

donde V_i es el valor bruto de la reserva, m el margen de contribución y r_{t_i} la fracción no recuperada correspondiente al tipo de evento —No-Show o cancelación tardía—. El beneficio potencial de intervenir correctamente sobre esa reserva fue

$$B_i = L_i \times e,$$

donde e representa la proporción de la pérdida que la acción consigue reducir mediante confirmación, garantía de pago, cancelación anticipada o reventa del inventario.

El resultado económico neto de una política se calculó como

$$A = \sum_{i \in D} B_i - N_c c - N_{nc} h,$$

donde D es el conjunto de eventos críticos detectados, N_c la cantidad total de contactos, c el costo unitario de contacto, N_{nc} la cantidad de intervenciones sobre casos no críticos y h su posible costo adicional. Como el dataset no permite estimar descuentos innecesarios, fricción ni cancelaciones inducidas, h se mantuvo en cero en los escenarios iniciales. Los parámetros se trataron como supuestos de sensibilidad y no como cantidades observadas.

3.8. Política preventiva propuesta

La política operativa considerada consiste en contactar las reservas priorizadas para solicitar confirmación y, cuando corresponda, una garantía de pago o prepago. La intervención no se interpreta exclusivamente como un medio para impedir la cancelación: también puede asegurar parte del valor o provocar una cancelación con mayor anticipación, liberando inventario para su posible reventa.

El contacto puede tener además un efecto adverso. La fricción introducida podría inducir la cancelación de una reserva que, sin intervención, se habría concretado. El dataset no identifica cancelaciones inducidas ni permite estimar su frecuencia. Este efecto se reconoció como limitación y posible costo de intervenir falsos positivos. Se conservó como parámetro explícito con valor inicial cero porque no existe una magnitud observada.

La comparación operativa utilizó capacidades iguales en lugar de un threshold común, porque los modelos producen scores con distribuciones y calibraciones diferentes. Se evaluaron los primeros 5, 10, 20 y 30 % del ranking de cada modelo contra una selección aleatoria de igual tamaño.

3.9. Primer lote de ingeniería de variables

Las variables nuevas se evaluaron con la regresión logística y sus hiperparámetros fijos, manteniendo los mismos folds y grupos. El holdout de 2017 no participó en la selección. Se estudiaron sumas de huéspedes y noches, un indicador doméstico, representaciones alternativas del historial y una interacción entre lista de espera y tipo de hotel.

TotalGuests y **TotalNights** no mejoraron ROC AUC y generaron dependencias lineales exactas con sus componentes. **IsDomestic** resultó redundante con la categoría portuguesa de

Country. Para historial y lista de espera se realizaron ablaciones que compararon agregar indicadores, ratios y reemplazar las variables originales.

El conjunto lineal seleccionado reemplaza **PreviousCancellations** por **PreviousCancellationRate**, y **DaysInWaitingList** por **WasOnWaitingList** y **CityHotelWasOnWaitingList**. También excluye **ArrivalDateWeekNumber**. No incorpora **TotalGuests**, **TotalNights**, **IsDomestic** ni **HasPreviousCancellation**. Esta selección es específica de regresión logística; las representaciones útiles para árboles se evaluaron por separado.

3.10. Segundo lote de ingeniería de variables

El segundo lote estudió representaciones no lineales sobre el conjunto parsimonioso. Se evaluaron codificaciones cíclicas del mes y del día de la semana, una transformación logarítmica y bandas operativas de **LeadTime**, y los indicadores **HasSpecialRequests** y **HasParking**. Cada familia se comparó primero de forma aislada y las mejoras consistentes se combinaron posteriormente, manteniendo fijos el modelo, los grupos y las particiones de validación.

Para regresión logística se seleccionó **LeadTimeBand** en reemplazo de **LeadTime**. Sus intervalos son: mismo día, 1–7, 8–30, 31–90, 91–180, 181–365 y más de 365 días. Esta representación permite asignar un efecto diferente a cada rango sin imponer una relación lineal común. También se agregó **HasSpecialRequests**, indicador de al menos una solicitud especial, conservando el conteo original. La selección fue específica del modelo lineal y no se trasladó automáticamente a modelos capaces de aprender cortes no lineales sobre la variable continua.

3.11. Regresión logística mejorada

La versión mejorada utilizó el conjunto lineal seleccionado y el mismo preprocesamiento reproducible del baseline. Sobre 2015–2016 se compararon $C \in \{0,001; 0,01; 0,1; 1; 10; 100\}$, pesos de clase nulos o balanceados y regularización L1 o L2. La búsqueda comprendió 24 configuraciones evaluadas mediante los mismos cinco folds estratificados y agrupados. Se utilizó el solver **liblinear** y ROC AUC como criterio de selección.

Una vez seleccionada la configuración se reajustó sobre todo el conjunto de desarrollo y se evaluó una única vez sobre el holdout temporal. Para estudiar la interpretación y estabilidad, el mejor esquema también se reajustó dentro de cada fold y se compararon sus coeficientes. Las variables numéricas fueron estandarizadas, por lo que sus coeficientes representan cambios en unidades de desviación estándar. Las categorías con muy baja frecuencia se interpretaron con cautela aun cuando presentaran coeficientes grandes.

3.12. Árbol de decisión e importancia de variables

Se entrenó un árbol de decisión regularizado sobre el conjunto base depurado, conservando **LeadTime** continuo y los conteos originales. La primera búsqueda comparó criterio Gini y entropía, profundidades entre 4 y 10, **min_samples_leaf** entre 50 y 250 y pesos de clase nulos o balanceados. La selección utilizó exclusivamente los folds agrupados de desarrollo.

La importancia se estudió mediante reducción de impureza, cantidad de splits, profundidad de primera aparición e importancia por permutación. Esta última se calculó sobre el fold no utilizado para ajustar cada árbol y permutando las variables originales antes del preprocesamiento. Las columnas one-hot se agruparon por predictor de origen para las medidas estructurales.

Las variables con evidencia mínima se evaluaron mediante ablación. La poda seleccionada elimina **Babies**, **Children**, **IsRepeatedGuest**, **HasCompany**, **ReservedRoomType**, **ArrivalDateDayOfMonth** y **Meal**, además de la exclusión previa de **ArrivalDateWeekNumber**. Antes de consultar el holdout se realizó una búsqueda final sobre el conjunto de 17 variables, comparando profundidades 8, 10, 12 y 14 y hojas mínimas de 75, 100, 150 y 250. La evaluación de 2017 no se utilizó para reajustar el modelo.

3.13. Random Forest

Random Forest comparó la base depurada de 24 variables con la poda de 17 mediante un bosque fijo y los mismos folds construidos sobre el conjunto más reducido. El conjunto ganador se utilizó en una búsqueda sobre profundidad, tamaño mínimo de hoja y proporción de variables candidatas por split. Los pesos se calcularon en cada muestra bootstrap mediante `balanced_subsample`.

La búsqueda original conservó 12 configuraciones para documentar la exploración. Debido a su costo, una grilla de confirmación comparó las dos profundidades relevantes con 100 árboles, manteniendo `max_features=0.5` y `min_samples_leaf=5`. La reducción del número de árboles se utilizó para abaratar la búsqueda; el holdout no participó en la selección ni se utilizó para una nueva iteración.

3.14. XGBoost

XGBoost utilizó el conjunto podado de 17 variables, que obtuvo una ventaja mínima frente a la base depurada con una configuración fija y reduce el ruido en un modelo de alta capacidad. Se fijaron 150 estimadores, tasa de aprendizaje 0,08, muestreo de filas y columnas de 0,8 y regularización L2 de 5. La razón entre clases de desarrollo se utilizó como `scale_pos_weight`.

La búsqueda se dividió en dos grillas pequeñas para evitar una exploración combinatoria costosa. Primero se compararon profundidades 3 y 5 con `min_child_weight` 5 y 15; después se extendió solamente la profundidad a 7. La configuración se seleccionó usando exclusivamente validación cruzada y considerando conjuntamente media, dispersión y gap train-validación. El holdout temporal se evaluó una sola vez después de cerrar la decisión.

3.15. KNN

KNN se evaluó como representante de los modelos basados en distancia. Las variables numéricas se estandarizaron y las categóricas se codificaron mediante One-Hot Encoding dentro del pipeline. Se utilizó el conjunto podado de 17 variables para reducir dimensiones irrelevantes, que pueden degradar las distancias entre observaciones.

Debido al costo cuadrático aproximado de comparar vecinos sobre decenas de miles de reservas, la búsqueda de hiperparámetros se realizó sobre una muestra de grupos completos extraída exclusivamente de 2015–2016. Esta muestra no intervino en la evaluación temporal. Una vez seleccionados el número de vecinos y su ponderación, el pipeline se reajustó sobre todo el conjunto de desarrollo y se evaluó una única vez sobre 2017. Por ello, el ROC AUC interno de KNN se informa como una estimación sobre la muestra de búsqueda y no como una comparación exactamente equivalente a las CV completas de otros modelos.

3.16. Red neuronal MLP

La red neuronal se implementó mediante `MLPClassifier` sobre el conjunto podado de 17 variables. Las numéricas se estandarizaron y las categóricas se codificaron con One-Hot Encoding dentro del pipeline. La selección se realizó exclusivamente mediante los cinco folds externos estratificados y agrupados de 2015–2016, manteniendo 2017 reservado.

Se partió de dos capas ocultas de 32 y 16 neuronas, ReLU, Adam, regularización L2, batch 128 y 150 épocas. La comparación posterior estudió early stopping, arquitecturas de una y dos capas, `alpha`, learning rate y batch size, modificando una familia de parámetros por vez. Finalmente se confirmó mediante un bloque 2×2 la interacción entre los dos mejores learning rates y batches.

Early stopping reserva internamente un 15 % aleatorio de los datos recibidos y decide detenerse mediante Accuracy. Esa partición no respeta los grupos y su métrica no coincide con el ROC AUC externo. Esta limitación se documentó; la selección principal continuó dependiendo de los folds externos agrupados. La configuración cerrada fue una capa de 32 neuronas, `alpha=0.01`,

learning rate 0,001, batch 64, paciencia de 15 épocas y máximo de 300. El holdout no se utilizó para nuevos ajustes.

3.17. Modelos y criterio de evaluación

El baseline se construyó con una regresión logística, preprocesamiento reproducible y una búsqueda deliberadamente pequeña. Posteriormente se evaluaron regresión logística, árbol de decisión, Random Forest, XGBoost, KNN y una red neuronal, con el objetivo de comparar familias de modelos lineales, basados en árboles, distancia y aprendizaje neuronal.

ROC AUC fue la métrica técnica principal porque evalúa el ordenamiento del riesgo sin fijar anticipadamente un umbral de decisión. El umbral 0,5 se conservó como referencia para las métricas de clasificación. La decisión operativa se analizó posteriormente mediante capacidades iguales, dado que los costos reales y la respuesta causal a la intervención no están observados.

4. Resultados

4.1. Baseline técnico

El holdout temporal contiene 40.687 reservas de enero a agosto de 2017, con una tasa de cancelación de 38,70 %. El conjunto de desarrollo contiene 78.703 reservas de 2015 y 2016, con una tasa de 36,19 %.

El `DummyClassifier` asigna a todas las observaciones la probabilidad previa de cancelación del conjunto de desarrollo. Como esta probabilidad es inferior a 0,5, con dicho umbral predice siempre la clase mayoritaria. Su accuracy de 0,6130 no implica capacidad predictiva: no detecta ninguna cancelación y su ROC AUC es 0,5.

La búsqueda de regresión logística seleccionó $C = 10$ y pesos de clase balanceados. El ROC AUC medio de validación cruzada agrupada fue 0,8925, con desviación estándar 0,0036. Sobre el holdout temporal descendió a 0,8422. La baja dispersión entre folds indica estabilidad interna, pero la diferencia frente a 2017 muestra que la generalización temporal es más exigente.

Cuadro 1: Resultados del baseline sobre el holdout temporal.

Modelo	ROC AUC	Accuracy	Precision	Recall	F1
Dummy prior	0,5000	0,6130	0,0000	0,0000	0,0000
Regresión logística	0,8422	0,7061	0,5798	0,8740	0,6971

Con umbral 0,5, la regresión logística detectó 13.761 de las 15.745 cancelaciones. La matriz contiene 14.967 verdaderos negativos, 9.975 falsos positivos, 1.984 falsos negativos y 13.761 verdaderos positivos. El recall elevado es coherente con los pesos balanceados, pero se obtiene a costa de una cantidad considerable de falsos positivos.

4.2. Primer lote de ingeniería de variables

La comparación se realizó exclusivamente mediante validación cruzada agrupada sobre 2015–2016. Eliminar `ArrivalDateWeekNumber` produjo una caída de 0,000168 respecto al baseline histórico, considerada marginal frente a la reducción de redundancia temporal.

El conjunto parsimonioso superó ambas referencias en los cinco folds. El candidato redundante lo superó solamente en 0,000348 y requirió cuatro variables adicionales con asociaciones casi determinísticas. Se seleccionó por tanto el conjunto parsimonioso, que conserva aproximadamente el 79 % de la mejora adicional del candidato redundante sobre la base depurada y ofrece coeficientes más interpretables. El holdout temporal no se consultó durante esta decisión.

Cuadro 2: Comparación combinada del primer lote para regresión logística.

Conjunto	Features	ROC AUC CV	Desviación
Base depurada	24	0,892322	0,003538
Baseline histórico	25	0,892490	0,003574
Primer lote parsimonioso	25	0,893810	0,003613
Candidato redundante	29	0,894158	0,003896

4.3. Segundo lote de ingeniería de variables

La transformación de **LeadTime** produjo la mejora principal. Agregar `log1p(LeadTime)` al conjunto parsimonioso elevó el ROC AUC medio a 0,904913. **HasSpecialRequests** también mejoró de forma consistente y, al combinarlo con ambas representaciones de **LeadTime**, se alcanzó 0,908554. La alternativa que reemplaza el valor continuo por bandas operativas y agrega **HasSpecialRequests** obtuvo 0,908447, con desviación 0,004005.

Cuadro 3: Comparación combinada del segundo lote para regresión logística.

Configuración	Features	ROC AUC CV	Desviación
Primer lote parsimonioso	25	0,893810	0,003613
LeadTime + logaritmo	26	0,904913	0,004321
LeadTime + logaritmo + solicitudes	27	0,908554	0,004228
Bandas de anticipación + solicitudes	26	0,908447	0,004005

La diferencia entre las dos mejores configuraciones fue de sólo 0,000107. Se seleccionó la alternativa basada en bandas porque ofrece una interpretación operativa directa, evita conservar simultáneamente dos representaciones muy asociadas de **LeadTime** y presenta una dispersión ligeramente menor. La mejora frente al primer lote fue de 0,014637 y se observó en los cinco folds. El holdout temporal de 2017 permaneció reservado.

4.4. Regresión logística mejorada

La búsqueda seleccionó $C = 1$, pesos de clase balanceados y regularización L1. El ROC AUC medio de validación cruzada fue 0,908557, con desviación 0,005873 y un gap train-validación de 0,003222. Sobre el holdout temporal alcanzó 0,855017, una mejora de 0,012817 frente al baseline. La caída de 0,053540 entre CV y 2017 indica que persiste una diferencia de generalización temporal, pero la mejora obtenida durante desarrollo se conserva fuera de muestra.

Cuadro 4: Comparación de Logistic Regression sobre el holdout temporal.

Modelo	ROC AUC	Accuracy	Precision	Recall	F1
Baseline	0,842200	0,706100	0,579800	0,874000	0,697100
Mejorado	0,855017	0,739032	0,620290	0,839568	0,713461

Con threshold 0,5 mejoraron Accuracy, Precision y F1, mientras que Recall se redujo en 0,034432. Este intercambio no se optimizó mediante el holdout porque ROC AUC no depende del threshold. Para la evaluación operativa posterior se compararon los modelos a igual capacidad y se conservó 0,5 sólo como referencia técnica.

La regularización L1 anuló 79 de las 229 columnas transformadas. Las bandas de **LeadTime** exhibieron un patrón monotónico: la cancelación observada aumentó desde 6,85 % para reservas del mismo día hasta 77,63 % para anticipaciones superiores a 365 días. **HasSpecialRequests**,

`TotalOfSpecialRequests` y `RequiredCarParkingSpaces` se asociaron con menor riesgo, mientras que `PreviousCancellationRate` se asoció con mayor riesgo.

Los mayores coeficientes positivos correspondieron a algunas categorías con muy pocos registros. Por ejemplo, `DistributionChannel=Undefined` apareció cinco veces y `ReservedRoomType=P`, seis. Estos valores se consideran señales inestables producidas por baja frecuencia y no evidencia general de importancia, aunque conservaran el signo entre folds.

4.5. Árbol de decisión

La importancia por permutación identificó como núcleo predictivo a `Country`, `MarketSegment`, `PreviousCancellations`, `LeadTime`, `TotalOfSpecialRequests`, `ArrivalDateYear`, `RequiredCarParkingSpaces` y `CustomerType`. Todas mostraron importancia positiva en los cinco folds. `LeadTime` participó en 40 splits, confirmando la relevancia de su relación no lineal con la cancelación.

La poda de 17 variables elevó el ROC AUC interno de 0,923749 a 0,924418 y mejoró los cinco folds. La búsqueda final seleccionó profundidad 14, `min_samples_leaf=75`, entropía y pesos balanceados. El árbol final contiene 392 hojas y 783 nodos.

Cuadro 5: Comparación técnica del árbol y Logistic Regression.

Modelo	ROC AUC CV	ROC AUC 2017	Accuracy	Precision	Recall	F1
LR baseline	0,892500	0,842200	0,706100	0,579800	0,874000	0,697100
LR mejorada	0,908557	0,855017	0,739032	0,620290	0,839568	0,713461
Árbol podado	0,927092	0,838694	0,765822	0,723456	0,639187	0,678716

Aunque el árbol obtuvo el mejor ROC AUC en validación cruzada, descendió a 0,838694 sobre 2017 y presentó un gap temporal de 0,088398. Con threshold 0,5 fue más preciso y alcanzó mayor Accuracy, pero omitió una proporción mayor de cancelaciones y obtuvo menor Recall y F1 que la regresión mejorada. Se conserva como herramienta para comprender y reducir variables, pero no como el mejor modelo temporal. El resultado del holdout no se utilizó para una nueva búsqueda.

4.6. Random Forest

Con un bosque fijo, la base depurada de 24 variables obtuvo ROC AUC medio 0,926422 frente a 0,925012 del conjunto podado y ganó cuatro de los cinco folds. Esto indica que algunas variables poco útiles para un árbol individual pueden contribuir a la diversidad del ensemble.

La búsqueda amplia seleccionó profundidad libre, `max_features=0.5` y `min_samples_leaf=5`. La grilla de confirmación con 100 árboles reprodujo la selección y alcanzó ROC AUC CV 0,941260, sólo 0,000307 menos que la ejecución con 300 árboles. El ROC AUC de entrenamiento fue 0,987653, con gap train-CV de 0,046393.

Cuadro 6: Resultado temporal de Random Forest.

Modelo	ROC AUC CV	ROC AUC 2017	Accuracy	Precision	Recall	F1
LR mejorada	0,908557	0,855017	0,739032	0,620290	0,839568	0,713461
Árbol podado	0,927092	0,838694	0,765822	0,723456	0,639187	0,678716
Random Forest	0,941260	0,842641	0,769312	0,748885	0,607621	0,670898

Random Forest presentó el mejor Accuracy y Precision de los modelos evaluados, pero detectó sólo el 60,76 % de las cancelaciones. El ROC AUC cayó a 0,842641 en 2017, generando un gap temporal de 0,098618, y permaneció por debajo de Logistic Regression mejorada tanto en ROC AUC temporal como en F1. La configuración se cerró sin reajustarla a partir del holdout.

4.7. XGBoost

La primera grilla mostró una mejora clara al aumentar la profundidad de 3 a 5 y la segunda confirmó una nueva mejora con profundidad 7. La mayor media de CV fue 0,938565 con `min_child_weight=5`. Sin embargo, se seleccionó el valor 15 porque redujo el gap train–validación de 0,014283 a 0,013085 a cambio de sólo 0,000288 de ROC AUC.

Cuadro 7: Comparación técnica de los modelos finales sobre 2017.

Modelo	ROC AUC CV	ROC AUC 2017	Accuracy	Precision	Recall	F1
LR mejorada	0,908557	0,855017	0,739032	0,620290	0,839568	0,713461
árbol podado	0,927092	0,838694	0,765822	0,723456	0,639187	0,678716
Random Forest	0,941260	0,842641	0,769312	0,748885	0,607621	0,670898
XGBoost	0,938277	0,867291	0,781724	0,737476	0,676913	0,705898

XGBoost obtuvo el mayor ROC AUC temporal y Accuracy. Su gap CV–2017 fue 0,070986, menor que los observados en el árbol y Random Forest. Con threshold 0,5 presentó un compromiso más equilibrado entre Precision y Recall que los otros modelos basados en árboles. Logistic Regression mantuvo el mejor Recall y un F1 ligeramente superior. Por ello, la evaluación operativa posterior comparó sus probabilidades mediante políticas de igual capacidad.

4.8. KNN

La búsqueda de KNN se realizó sobre una muestra agrupada de 27.137 reservas de desarrollo para limitar el costo del cálculo de distancias. Se compararon 25 y 75 vecinos con ponderación uniforme o por distancia, utilizando tres folds. La configuración seleccionada empleó 75 vecinos ponderados y obtuvo ROC AUC medio 0,876338, con desviación 0,008868. Esta estimación sobre una muestra no es directamente comparable con las validaciones completas de los demás modelos.

El ROC AUC de entrenamiento cercano a uno de las configuraciones ponderadas no se tomó como evidencia convencional de sobreajuste: al predecir el propio entrenamiento, cada observación es su vecina a distancia cero. La comparación se basó en los folds no observados y la evaluación temporal posterior.

Cuadro 8: Resultado temporal de KNN.

Modelo	ROC AUC 2017	Accuracy	Precision	Recall	F1
KNN	0,825042	0,759751	0,743475	0,578914	0,650955

KNN presentó el menor ROC AUC temporal de los modelos entrenados. Aunque su Precision fue alta, omitió más de cuatro de cada diez cancelaciones. La pérdida de capacidad de ordenamiento es coherente con la dificultad de definir cercanía en el espacio de alta dimensión producido por One-Hot Encoding. Por este motivo no se amplió la grilla y el modelo se conserva como comparación de una familia basada en distancia, no como candidato final.

4.9. Red neuronal MLP

La red inicial (32, 16) obtuvo ROC AUC CV 0,930352. Activar early stopping mejoró los cinco folds, elevó la media a 0,933210, redujo el gap train–CV de 0,034510 a 0,025188 y disminuyó el entrenamiento medio de 150 a 64,6 épocas. La comparación de arquitecturas seleccionó una única capa de 32 neuronas. La regularización elegida fue `alpha=0.01`; luego se conservaron learning rate 0,001 y batch 64 tras confirmar su interacción.

La configuración final alcanzó ROC AUC CV 0,936075, con desviación 0,002251 y gap train-CV 0,014919. El ajuste completo se detuvo después de 55 épocas. En el holdout temporal obtuvo los siguientes resultados:

Cuadro 9: Resultado temporal de la red neuronal MLP.

Modelo	ROC AUC CV	ROC AUC 2017	Accuracy	Precision	Recall	F1
MLP	0,936075	0,845721	0,627129	0,509632	0,964433	0,666872

El gap CV-2017 fue 0,090354. Con threshold 0,5 la red detectó 15.185 de las 15.745 cancelaciones y omitió solamente 560, pero produjo 14.611 falsos positivos. Por ello presentó el mayor Recall de los modelos ajustados y una Precision baja. Su ROC AUC temporal quedó por debajo de Logistic Regression y XGBoost: cambiar el threshold puede modificar el intercambio entre Precision y Recall, pero no mejora la capacidad de ordenamiento medida por ROC AUC. La red se conserva como comparación de una familia neuronal y no como candidato técnico principal.

La Figura 4 compara el comportamiento de los tres modelos candidatos a lo largo de todos los thresholds. XGBoost presenta la mayor área bajo la curva en el holdout temporal, seguido por Logistic Regression y MLP. La visualización complementa las métricas puntuales y evita que la comparación dependa de un único threshold de clasificación.




Figura 4: Curvas ROC de los modelos candidatos sobre el holdout temporal de 2017.

4.10. Comparación operativa a igual capacidad

Sobre 2017 se identificaron 1.598 eventos críticos: 348 No-Show y 1.250 cancelaciones registradas entre cero y siete días antes de la llegada. Su valor bruto elegible fue 540.098,62 unidades monetarias. Esta cantidad es exposición bruta y no una pérdida observada.

XGBoost mantuvo el mejor ordenamiento del target original. Dentro del 5 % de mayor score, el 99,90 % de las reservas terminó cancelando. Sin embargo, esa selección incluyó sólo 4 eventos

críticos, equivalentes a 0,25 % del total. El resultado muestra que las cancelaciones generales con mayor score no coinciden necesariamente con No-Show o cancelaciones tardías.

Cuadro 10: Captura operativa a igual capacidad.

Modelo y capacidad	Recall crítico	Captura de valor bruto	Lift
LR, 10 %	0,0720	0,1143	0,7196
LR, 20 %	0,2078	0,2600	1,0387
LR, 30 %	0,3254	0,3869	1,0846
XGBoost, 10 %	0,0357	0,0647	0,3567
XGBoost, 20 %	0,1189	0,1919	0,5944
XGBoost, 30 %	0,2760	0,3398	0,9198
MLP, 10 %	0,0350	0,0938	0,3504
MLP, 20 %	0,1327	0,2263	0,6633
MLP, 30 %	0,2146	0,3363	0,7154

Logistic Regression fue la mejor alternativa para la evaluación crítica. Con capacidades de 20 y 30 % superó la selección aleatoria tanto en cantidad de eventos como en valor bruto. En 5 y 10 % detectó menos eventos que el azar, aunque capturó una proporción de valor bruto superior.

La Figura 5 permite observar esta diferencia para todas las capacidades evaluadas. La diagonal representa la captura esperada mediante una selección aleatoria: una curva por encima de esa referencia indica una concentración útil de eventos o de valor en los primeros lugares del ranking.




Figura 5: Captura de eventos críticos y de valor bruto según la capacidad operativa.

4.11. Diagnóstico del desalineamiento del objetivo

Las distribuciones de scores muestran que las cancelaciones no críticas reciben valores mayores. En XGBoost, su score mediano fue 0,7830, frente a 0,3664 para cancelaciones tardías y 0,4803 para No-Show.

Cuadro 11: ROC AUC del target original y del evento crítico retrospectivo.

Modelo	Cancelación general	Crítico vs. todos	Crítico entre cancelaciones
Logistic Regression	0,855017	0,565019	0,293529
XGBoost	0,867291	0,563477	0,251317
MLP	0,845721	0,497290	0,219339

Los ROC AUC inferiores a 0,5 dentro de las reservas canceladas indican que los scores tienden a ordenar primero las cancelaciones no críticas. Por tanto, el proyecto mantiene **Cancelled** como objetivo y limita la interpretación económica de sus predicciones. Entrenar un modelo específico para **IsCriticalCancellation** se propone como trabajo futuro; no se reabre el ciclo de modelado con información observada en el holdout.

4.12. Del baseline al modelo económico final

La primera formulación, aplicada al baseline con umbral 0,5, requería contactar 23.736 reservas, equivalentes al 58,34 % del holdout, y sólo el 4,97 % de esas intervenciones correspondía a un evento crítico. Esta carga operativa y el supuesto extremo de interpretar todo el valor bruto como pérdida motivaron el reemplazo de la matriz de confusión por políticas de capacidad limitada y del valor bruto por una pérdida estimada mediante escenarios.

4.13. Evaluación económica por escenarios

El cálculo final reemplazó el supuesto extremo de pérdida total por tres escenarios. Para cada evento se aplicaron un margen de contribución, una fracción no recuperada específica para **No-Show** o cancelación tardía, una proporción de reducción de la pérdida y un costo por contacto. Estos parámetros representan supuestos de sensibilidad y no cantidades observadas.

Cuadro 12: Parámetros de los escenarios económicos.

Escenario	Margen	No-Show	Tardía	Reducción	Contacto
Conservador	50 %	70 %	25 %	10 %	10
Intermedio	70 %	90 %	50 %	30 %	5
Favorable extremo	85 %	100 %	75 %	50 %	2

La columna *No-Show* indica la fracción no recuperada para ese evento; *Tardía*, la correspondiente a cancelaciones entre cero y siete días; y *Reducción*, la proporción de la pérdida detectada que la intervención consigue reducir. El costo adicional por caso no crítico se mantuvo en cero en los tres escenarios.

Cuadro 13: Ahorro neto esperado por modelo, capacidad y escenario.

Modelo	Capacidad	Conservador	Intermedio	Favorable extremo
Logistic Regression	5 %	-19.583,77	-4.744,17	10.991,97
Logistic Regression	10 %	-39.542,60	-12.461,08	13.310,12
Logistic Regression	20 %	-78.702,33	-22.503,01	32.835,12
Logistic Regression	30 %	-118.135,18	-34.154,66	48.443,20
XGBoost	5 %	-20.236,77	-9.223,88	-1.182,68
XGBoost	10 %	-39.984,82	-15.672,39	4.274,58
XGBoost	20 %	-79.389,11	-27.210,18	20.049,69
XGBoost	30 %	-118.578,04	-37.293,16	39.739,39
MLP	5 %	-19.948,70	-7.108,66	4.807,05
MLP	10 %	-39.900,97	-14.444,98	8.741,71
MLP	20 %	-79.331,84	-25.912,60	25.145,48
MLP	30 %	-118.968,68	-38.862,45	37.400,91

Ninguna política produjo ahorro en los escenarios conservador e intermedio. La alternativa más cercana al equilibrio fue Logistic Regression con capacidad de 5 % en el escenario intermedio: el ahorro neto fue -4744,17 unidades y la reducción de pérdida necesaria para alcanzar el equilibrio fue 56,21 %, frente al 30 % supuesto.

Los resultados fueron positivos principalmente en el escenario favorable extremo. Logistic Regression obtuvo 10 991,97 unidades con capacidad de 5 % y 48 443,20 con 30 %, aunque esta última alternativa exige 12.207 contactos. Por ello, maximizar el ahorro calculado no implica automáticamente una política operativamente conveniente.

Logistic Regression presentó el mejor resultado económico, mientras que XGBoost conservó el mayor ROC AUC para **Cancelled**. Esta diferencia confirma que ordenar cancelaciones generales no equivale a priorizar los eventos críticos. Además, el costo adicional de falsos positivos se mantuvo en cero porque no es posible estimar con los datos los descuentos innecesarios, la fricción o las cancelaciones inducidas por el contacto. Su incorporación reduciría los ahorros calculados.

En consecuencia, la política sólo muestra viabilidad bajo supuestos favorables y no se presenta como una fuente de ahorro demostrada. Se propone como trabajo futuro entrenar directamente un modelo para **IsCriticalCancellation**.

5. Conclusiones

El proyecto evaluó la posibilidad de anticipar cancelaciones de reservas hoteleras y utilizar las probabilidades estimadas para priorizar acciones preventivas. La separación temporal entre desarrollo (2015–2016) y holdout (2017) permitió observar una dificultad que una partición aleatoria habría ocultado parcialmente: todos los modelos presentaron una caída de rendimiento al generalizar hacia un período posterior.

XGBoost obtuvo el mejor ordenamiento del target original, con ROC AUC 0,867291 sobre 2017 y Accuracy 0,781724. Logistic Regression mejorada alcanzó ROC AUC 0,855017, el mayor F1 (0,713461) y una estructura más interpretable. La MLP consiguió el mayor Recall (0,964433) con threshold 0,5, pero a costa de 14.611 falsos positivos. El árbol resultó especialmente útil para estudiar y reducir variables, mientras que Random Forest y KNN no superaron a los candidatos principales en el holdout temporal.

La ingeniería de variables produjo una mejora clara en el modelo lineal. La representación por bandas de **LeadTime**, las solicitudes especiales y el historial relativo de cancelaciones permitieron mejorar el baseline sin utilizar el holdout para seleccionar alternativas. También se descartaron variables redundantes o con riesgo de leakage, priorizando una representación más parsimoniosa y disponible al momento de la predicción.

La evaluación operativa reveló que el objetivo técnico y el objetivo económico no están completamente alineados. Los modelos distinguen adecuadamente las cancelaciones generales, pero asignan scores mayores principalmente a cancelaciones no críticas. Dentro de las reservas canceladas, los ROC AUC para distinguir No-Show y cancelaciones tardías fueron inferiores a 0,5. Por este motivo, XGBoost fue el mejor modelo técnico, mientras que Logistic Regression produjo la mejor priorización económica entre los candidatos analizados.

El valor bruto de una reserva no se interpretó como pérdida observada. El análisis final incorporó margen de contribución, fracciones no recuperadas por tipo de evento, efectividad de la intervención y costo por contacto. Ninguna política resultó rentable bajo los escenarios conservador e intermedio. Los ahorros fueron positivos principalmente en el escenario favorable extremo y dependieron de supuestos que el dataset no permite verificar. Además, no fue posible cuantificar descuentos innecesarios, fricción ni cancelaciones inducidas por el contacto. En consecuencia, el sistema no demuestra por sí solo una fuente de ahorro y no justifica una implementación operativa sin validación adicional.

5.1. Limitaciones

Los datos proceden de dos hoteles portugueses y cubren solamente el período comprendido entre julio de 2015 y agosto de 2017, por lo que los resultados no se generalizan automáticamente a otros establecimientos o contextos. Algunas variables categóricas presentan niveles de muy baja

frecuencia, y las diferencias temporales observadas sugieren posibles cambios en la distribución de los datos.

El dataset tampoco contiene el margen real, los pagos efectivamente recuperados, la posibilidad de revender cada habitación, el costo de contacto ni la respuesta causal a una intervención. Los escenarios económicos permiten analizar condiciones de viabilidad, pero no estimar un ahorro contable real. Finalmente, `IsCriticalCancellation` se construyó retrospectivamente a partir del estado final y de su fecha; sólo puede utilizarse como target de un nuevo entrenamiento, nunca como predictor disponible al crear la reserva.

5.2. Trabajo futuro

La principal extensión consiste en repetir el ciclo de modelado utilizando `IsCriticalCancellation` como objetivo. Esto permitiría optimizar directamente la priorización de No-Show y cancelaciones tardías en lugar de esperar que un modelo de cancelación general las ordene adecuadamente.

Antes de una aplicación real también sería necesario estimar los parámetros económicos con información del hotel y diseñar una prueba controlada de la política de contacto. Dicha prueba debería medir confirmaciones, pagos garantizados, reventa del inventario, satisfacción del cliente y posibles cancelaciones inducidas. Con esos datos podrían ajustarse capacidad y threshold según beneficio neto, no solamente mediante métricas de clasificación.

Como extensiones técnicas adicionales pueden evaluarse calibración de probabilidades, monitoreo de drift temporal y nuevas búsquedas de hiperparámetros. Estas mejoras sólo tendrían sentido después de alinear el target con la decisión operativa y disponer de costos observados.